

基于扩散模型的敦煌壁画修复与视觉重建研究

Research on Dunhuang Mural Restoration and Visual Reconstruction Based on Diffusion Models

学院：计算机学院

学号：

专业：智能科学与技术

汇报人：郑炳旭

年级：2022级

指导老师：苏冠鹏

汇报时间：2026.05.10

1

选题背景及研究现状

Research Background and Current Status

2

研究创新点和难点

Research Innovations and Challenges

3

理论与技术基础

Theoretical and Technical Foundations

4

数据集及数据处理

Dataset and Data Processing

CONTENTS

5

核心算法及实验结果

Core Algorithms and Experimental Results

6

系统实现

System Implementation

7

总结与展望

Conclusion and Future Work

PART ONE

选题背景及研究现状

Research Background and Current Status



选题背景及研究现状



选题背景

敦煌壁画是中国古代艺术与文化遗产的瑰宝，在**历史、艺术与学术价值**方面皆具极高价值，其内容不仅承载了重要的文明史料，还吸收融合了中国各个朝代和西域的艺术风格，涵盖宗教、社会、科学等诸多领域的知识，被誉为“中古时代的百科全书”。

然而，受自然环境的侵蚀、年代久远以及人为破坏等因素的影响，壁画表面普遍存在**剥落、褪色、污损**等问题，导致大量珍贵信息丢失。

传统的壁画修复方式主要依赖人工绘制与经验判断，不仅**耗时耗力**，而且存在**主观性强、修复一致性差**等局限。

随着文物数字化与人工智能技术的发展，**数字化修复**成为文物保护的重要方向。



选题背景及研究现状


任务	模型/方法	核心思路	优点	启发
图像分割	SAM	基于大规模数据预训练的通用分割模型，通过提示机制实现零样本目标分割	泛化能力强，适用于多种分割场景	具备良好的通用分割能力，可通过针对性微调和网络结构改造来提升壁画病害检测精度
图像分割	SAM-Adapter	在SAM框架中引入轻量级Adapter模块，实现参数高效微调	参数量少，原用于医学分割，对于小目标及边界模糊区域具有更好的分割性能	迁移至壁画病害检测任务，结合数据增强提升模型检测精度
图像修复	MuralDiff	基于扩散模型的壁画修复方法，利用边缘信息优化掩膜构建，并结合裂缝检测引入结构先验，采用两阶段机制实现修复与细化	边缘连续性与结构完整性较好，生成结果自然	为壁画病害修复引入结构约束信息
图像生成 / 图像修复	ControlNet	在扩散模型中引入条件控制（如边缘、姿态等）	可实现可控生成	使用壁画轮廓进行条件控制



选题背景及研究现状

研究方法

- 输入损坏壁画图像，基于 SAM-Adapter 模型进行病害区域检测，生成病害掩码及其反掩码；
- 利用 XDoG 算子提取壁画结构轮廓，并进行人工修复以获得完整结构信息；
- 将损坏图像与修复后的轮廓图输入 ControlNet，在掩码约束下生成修复图像；
- 对修复结果进行超分辨率重建，得到高清壁画图像；
- 基于通义万相模型（wan2.6-i2v），结合文本 Prompt 生成动态壁画视频。



PART TWO

研究创新点和难点

Research Innovations and Challenges

创新点

1 数据层面

在数据层面，针对敦煌壁画图像样本稀缺、分布不均等问题，**整合现存的数据集**（如 MuralDH、Dunhuang_Faces 等），并结合**数据增强**技术，构建覆盖多种损坏类型的**大规模壁画数据集**，从而提升模型的修复精度与鲁棒性。

2 模型层面

在模型层面，提出一种融合**轮廓引导与掩码约束**的**潜空间**扩散修复方法。通过引入 XDoG 提取的**结构轮廓**作为 ControlNet 条件，实现结构一致性引导；同时结合**病害掩码与反掩码**的双重约束，精确限定修复区域。在此基础上，融合**多尺度特征**以提升纹理细节表达，并依托潜空间扩散**降低计算开销**，实现高质量与高效率的统一。

3 应用层面

在应用层面，基于 PySide6 构建可视化交互系统，集成**病害检测、轮廓与掩码编辑、图像修复、超分辨率及视频生成**等功能，实现从**算法到应用**的完整落地，为敦煌壁画的数字化保护与艺术再现提供可视化解决方案。

★ 难点

1 数据层面

在数据层面，采用**真实病害掩码**训练时，因缺少**完好壁画区域**的真实参考，难以全面评估模型性能。为此，在真实掩码基础上引入**人工生成**的**伪病害掩码**，增强病害形态与分布的多样性，从而构建更全面的评估体系，并提升模型的泛化能力。

2 模型层面

在模型层面，病害掩码在映射至潜空间分辨率时，**细线状区域**易因下采样发生**信息丢失**，导致掩码覆盖不完整。为此，引入**高斯膨胀**对压缩后的掩码进行适度扩展，以提升病害区域的覆盖完整性。

3 优化层面

在优化层面，受限于**计算资源**，采用 **LDM** 模型降低计算开销，并结合**多 GPU 分布式**训练与 Accelerator **混合精度**训练策略，提高训练效率。


PART THREE

理论与技术基础

Theoretical and Technical Foundations



SAM-Adapter模型及其适配机制



SAM-Adapter 是在通用分割模型 **SAM** 基础上提出的轻量化适配方法，旨在解决 SAM 在复杂场景下分割性能不足的问题。其核心思想是在保持 SAM 图像编码器参数冻结的前提下，引入轻量级 Adapter 模块，实现对特定任务的高效适配。

在结构上，SAM-Adapter 在图像编码器中嵌入基于卷积的 Adapter 分支，用于增强局部细粒度特征表达，并通过特征融合机制与原有 Transformer 特征进行结合，从而弥补 SAM 在局部结构建模方面的不足。

相比传统全参数微调方法，该方法仅需训练少量新增参数，在降低计算开销的同时，有效提升模型在小区域、边界模糊等复杂分割任务中的性能表现。



XDoG边缘检测算子原理

$$DoG(x) = (1 + \gamma)G_{\sigma}(x) * I(x) - \gamma G_{k\sigma}(x) * I(x)$$

其中， $I(x)$ 表示输入图像， $G_{\sigma}(x)$ 和 $G_{k\sigma}(x)$ 分别表示标准差为 σ 和 $k\sigma$ 的高斯滤波核， $*$ 表示卷积运算， γ 为权重系数。

$$XDoG(x) = \begin{cases} 1, & D(x) \geq \epsilon \\ 1 + \tan h(\phi(D(x) - \epsilon)), & otherwise \end{cases}$$

其中， $D(x)$ 表示DoG算子的输出结果， ϵ 为阈值参数，用于控制边缘提取的敏感程度， ϕ 为控制函数陡峭程度的参数。


XDoG（扩展差分高斯）是在传统 **DoG** 算子的基础上改进的边缘检测方法，通过多尺度高斯滤波差分增强图像边缘信息，并结合非线性阈值函数对结果进行进一步强化。

具体而言，XDoG 首先利用不同尺度的高斯滤波提取图像的高频信息（边缘），随后通过非线性增强函数提升边缘响应、抑制背景噪声，从而获得更加清晰、连续的结构轮廓。

相比传统边缘检测方法，XDoG 在保持细节的同时具有更强的抗噪能力，能够生成平滑且连贯的线条结构。



ControlNet条件控制机制




ControlNet 是一种用于增强扩散模型可控性的条件控制方法，在不改变原有模型能力的前提下，通过引入结构化条件信息实现对生成过程的精确引导。

其核心是在U-Net去噪网络基础上构建额外的**控制分支**，用于接收边缘、轮廓等结构信息，并在**多尺度特征层**中注入到主网络，从而在扩散去噪过程中实现结构约束。

同时，通过**零卷积连接**与**冻结主干参数**，仅训练控制分支，使模型在保持生成质量的同时实现稳定高效的条件学习。



SinSR超分辨率



SinSR是一种基于扩散模型的**单步**图像**超分辨率**方法，通过将传统多步去噪过程蒸馏为一步映射，实现高质量与高效率兼顾的图像重建。

具体而言，SinSR首先将扩散模型的**随机采样**过程转化为**确定性映射**，并以加速扩散模型（如**ResShift**）作为**教师模型**，构建从初始噪声到高分辨率图像的映射关系；随后通过**知识蒸馏**训练学生网络，使其能够在单次前向传播中完成超分辨率重建；同时引入**一致性保持损失**，利用真实高分辨率图像进行约束，进一步提升生成结果的细节真实性与结构一致性。



图像动态化

输入提示词	输入首帧图像	输出视频（多镜头，有声视频）
镜头从海龟下方缓缓上移，海龟悠然游动，腹部细节清晰可见。		

通义万相是一种基于**扩散模型**的**多模态**生成框架，支持从**图像到视频**的自动生成。其通过引入时空建模机制，在保持输入图像语义与风格一致性的基础上，实现时间连续的视频内容生成。

在壁画动态化任务中，模型以修复后的壁画图像为条件，通过**多模态编码**提取**语义**与**结构**信息，并在**潜空间**中进行时空建模，通过扩散去噪过程逐步生成**连续视频帧**，从而实现由静态到动态的转换。

该方法能够保持主体、风格与结构一致，同时生成连贯运动，并支持多镜头切换与一致性控制，从而提升视频的真实感与表现力。


PART FOUR

数据集及数据处理

Dataset and Data Processing



数据集及数据处理



整合数据集示例

最终构建数据集：

- 训练集：14275张
- 验证集：1154张



数据整合：

- 统一图像尺寸为 512×512
- 剔除尺寸小于 256 像素的低质量图像
- 对高分辨率图像采用滑动裁剪，提升样本数量并保留细节
- 对非正方形图像进行合理裁剪+缩放



数据构建：

- 基于 SAM-Adapter 提取病害区域，生成掩码图
- 利用 XDoG 算子提取结构轮廓信息



数据增强：

- 几何增强：翻转、旋转，提高方向鲁棒性
- 质量扰动：高斯模糊，增强抗退化能力
- 光照与颜色增强：亮度/对比度调整、颜色抖动
- 数据规范化：归一化 + 掩码二值化



数据集及数据处理




图 3-3 模拟真实病害掩码

图 3-4 伪病害掩码

图 3-5 模拟真实病害掩码叠加伪病害掩码

伪病害掩码示例



在比例控制方面：

- 计算真实病害掩码在图像中的面积占比
- 设定伪病害最大占比为 40%
- 构建自适应调节机制：
 - 真实病害多 → 减少伪病害
 - 真实病害少 → 增加伪病害



在形态模拟方面：

- 随机生成多种遮挡结构：
 - 矩形块（剥落）
 - 随机线条（不规则损伤）
 - 细线结构（裂纹）



在真实性增强方面：

- 对掩码边缘施加高斯模糊（Gaussian Blur），提升边缘过渡自然性，贴近真实病害形态

PART FIVE

核心算法及实验结果


Core Algorithms and Experimental Results



核心算法及实验结果


壁画病害区域检测

- **模型框架**: 基于 **SAM (ViT-H)** 构建 SAM-Adapter, 在冻结原始图像编码器参数的基础上, 引入 Adapter 模块实现参数高效微调, 提升对壁画病害特征的适应能力。
- **结构改进**: 在每个 **Transformer Block** 后插入 **Adapter**, 在保持原有特征表达能力的同时降低训练成本。
- **分辨率适配**: 通过双线性插值对 **Position Embedding** ($64 \times 64 \rightarrow 32 \times 32$) 及 **预测掩码** 进行 **重采样**, 使模型适配 512×512 输入图像。
- **分割策略**: 采用 **全图自动分割** 方式, 无需点/框提示, 实现壁画病害区域的自动检测, 提高处理效率。
- **损失函数设计**: 采用 **Focal Tversky Loss** + **BCE Loss** 组合损失, 兼顾像素级分类精度与区域重叠度, 有效提升小面积病害检测能力。
- **训练策略**: 采用 **带预热的余弦学习率衰减**, 结合 **梯度累计** 与 **混合精度** 训练, 在有限显存条件下提升训练稳定性与效率。





核心算法及实验结果




不同模型的病害区域检测效果对比图

方法	平均IoU
无微调SAM	0.0398
SAM + FocalTverskyBCELoss	0.1053
SAM-Adapter + BCEDiceLoss	0.3187
SAM-Adapter + FocalTverskyBCELoss	0.3404



核心算法及实验结果



壁画轮廓提取

使用扩展差分高斯 (XDoG) 算子对敦煌壁画图像进行结构信息提取。

- (1) 对输入图像分别进行不同尺度 (σ_1 与 σ_2) 的高斯模糊处理，以获得多尺度平滑结果。
- (2) 引入加权系数 k (sharpen) 对两尺度模糊结果进行线性组合，计算并应用加权差异图像，从而增强边缘信息并提高细节对比度。
- (3) 引入阈值 ϵ (epsilon) 对响应结果进行初步分割，并结合双曲正切函数 (tanh) 实现软阈值增强，其中参数 ϕ (phi) 用于控制非线性映射的斜率，从而调节边缘对比度与过渡平滑程度，在保留细节信息的同时有效抑制噪声干扰。
- (4) 最终对原始掩码与软阈值处理结果进行归一化，得到清晰的结构轮廓图。



核心算法及实验结果



Original Image



Final XDoG Result



最终采用参数生成的轮廓图

在多组参数配置的可视化对比实验中，当参数设置为 $\sigma_1=1.0$ 、 $\sigma_2=1.2$ 、 $\phi=0.1$ 、 $\epsilon=0$ 、 $\text{sharpen}=100$ 时，提取出的轮廓图能在较好保留结构线条的同时，能够有效抑制部分纹理噪声，整体视觉效果较为接近人工绘制的线稿图，如上图所示。



核心算法及实验结果

半透明块为冻结参数
其余为可训练参数




修复模型的设计 (LDM + ControlNet)

- **整体框架**：基于 **Stable Diffusion** (LDM) 构建壁画修复模型，在潜空间中进行扩散与去噪，降低计算开销并提升生成效率。
- **结构设计**：引入 **ControlNet** 控制分支，将**轮廓结构**信息作为条件输入，在U-Net**多尺度特征**中注入结构约束，实现结构可控生成。
- **双条件约束机制**：
 - **结构约束**：利用**线稿轮廓引导**生成结果保持原有结构一致性。
 - **区域约束**：结合 SAM-Adapter 生成的病害掩码，仅在**病害区域**进行修复，保持完好区域不被破坏。
- **掩码优化**：针对潜空间下采样导致的细小病害区域丢失问题，引入**高斯膨胀**扩充掩码覆盖范围，提高修复完整性。
- **训练策略**：**冻结 VAE 与 U-Net**，仅**微调 ControlNet**；采用 MSE 损失 + AdamW 优化器 + Warmup 余弦学习率，结合 Accelerate **多GPU分布式训练**与**混合精度**加速，在保证训练稳定性的同时显著提升计算效率并降低显存开销。



核心算法及实验结果




有无微调ControlNet可视化结果对比

方法	平均PSNR	平均MS-SSIM	平均MSE
无微调ControlNet	11.9097	0.5985	0.0692
微调ControlNet	17.3914	0.8106	0.0198



核心算法及实验结果



(a) 扩散完后直接恢复完好区域与 (b) 在扩散中逐步恢复完好区域的修复对比图

在扩散去噪过程中，本文在每一步引入掩码约束：**在病害区域进行生成，完好区域保持原始加噪结果**，保证修复范围受控并维持结构与**色彩一致性**，避免产生明显色差。



核心算法及实验结果



放缩掩码后有无使用高斯膨胀的修复结果对比图

在去噪迭代中，掩码需缩放到潜在变量的分辨率，但细小病害结构在下采样时易丢失，导致部分区域约束不足、修复不完整。为此，本文在掩码压缩后引入高斯膨胀，对放缩后掩码适度扩展，从而增强对病害区域的约束，提升修复的完整性与稳定性。



核心算法及实验结果



掩码与轮廓不同组合方式的消融实验可视化对比图

方法	平均PSNR	平均MS-SSIM	平均MSE
有掩码无轮廓	11.9097	0.5985	0.0692
有轮廓无掩码	17.3914	0.8106	0.0198
有掩码有轮廓	21.6988	0.9250	0.0079




核心算法及实验结果

		方法	平均PSNR	平均MS-SSIM	平均MSE
		MISF	15.6314	0.7781	0.0469
原图		EdgeConnect	20.5035	0.8958	0.0119
		Lama	20.8967	0.9067	0.0111
修复		微调ControlNet	21.6988	0.9250	0.0079
输入		不同修复方法的指标与可视化对比分析			
EdgeConnect					
Lama					
微调ControlNet					



核心算法及实验结果



本文研究方法在中国山水画数据集的修复效果

在 [Chinese-Landscape-Painting-Dataset](#) 数据集上，本文方法同样表现良好：随机选取100张图像进行掩码修复实验，结果显示 PSNR 达20.9398，MS-SSIM为0.8656，MSE为0.0131。表明该方法不仅适用于敦煌壁画修复，在风格差异较大的中国山水画数据集上也具有较好的泛化能力与结构保持能力。



核心算法及实验结果



超分辨率前




超分辨率后

壁画图像超分辨率设计

- **方法概述**: 基于 **SinSR** 单步超分辨率技术, 对修复后的敦煌壁画图像进行高分辨率重建, 提升图像细节与清晰度。
- **实现方式**: 调用预训练 SinSR 模型, 设置**推理参数** (输入输出路径、放大倍数、步数等), 结合 **ResShift 采样器** 完成图像生成。



核心算法及实验结果



修复前



修复后



动态化

壁画动态化设计 (Image-to-Video)

- **方法概述**: 基于 **Image-to-Video (I2V)** 技术, 将修复后的敦煌壁画图像转化为连续视频, 实现静态图像的动态化呈现, 增强展示沉浸感。
- **实现方式**: 调用**通义万相**图生视频模型接口, 以单张修复图像为输入, 通过扩散模型在时间维度生成连续帧, 无需人工动画设计。
- **语义控制**: 引入文本提示 (**Prompt**) 作为条件约束, 引导视频生成内容 (如人物动作、场景变化等), 提升生成结果的可控性与表现力。
- **参数调节**: 支持多种生成参数设置, 包括**视频分辨率**、**时长**及**镜头模式** (单镜头 / 多镜头) 等, 以适应不同展示需求。
- **结果获取**: 通过 **API** 请求获取视频下载链接, 并利用 **requests** 库自动完成视频文件的下载与本地保存, 以支持后续展示与播放。

PART SIX


系统实现

System Implementation




系统实现

敦煌壁画修复与视觉重建系统主要使用 **Pyside6** 实现，包括**模型导入模块**、**壁画病害区域检测模块**、**轮廓与病害区域掩码提取及编辑模块**、**壁画修复模块**、**壁画超分辨率模块**、**壁画动态化模块**。



模型导入模块



壁画病害区域检测模块

圖學修習

1. 完成线稿和透视的绘制
2. 设定好扩散系数（正整数）
3. 点击开始图像修复按钮并等待修复完成
4. 导出修复好的效果图



9080

开始训练呼吸

09-08-2006

超分辨率

1. 上传修复好的壁画图像
2. 点击开始图像部分按钮并等待部分完成
3. 导出部分分辨率的壁画图像



190

开始训练：

時計、電卓、計算機

线模提取

1. 提取或上传线稿
2. 自动或手动遮罩损坏区域
3. 在遮罩的遮罩区域进行线稿修补

結構导出

速導導出



DOI: 10.1002/anie.200500000

退出 导入模型 快速转

視頻化

1. 上传你最好的图像
2. 设定提示词、时长、分辨率、模型等参数
3. 点击动态化按钮生成图片动态化
4. 各模型支持的参数不一样，详情请到定义

[illegible]

112

1

2502

Conclusion and Future Work



结论与展望

结论：

本研究面向敦煌壁画数字化修复与重建，融合扩散模型、图像分割与数字图像处理等技术，构建了一套涵盖病害自动检测、轮廓结构约束、图像修复、超分辨率重建及动态化呈现的全流程智能修复方法，并完成了相关算法的工程化实现与可视化系统开发，为敦煌壁画的数字化修复与活态传承提供了具有可行性与推广价值的技术方案。

展望：

未来工作可以从以下方面优化：

- 1) 实现壁画轮廓自动补全，支持全自动修复流程；
- 2) 构建更大规模、高质量壁画数据集；
- 3) 引入多模态先验提升色彩一致性与真实感；
- 4) 探索三维重建与VR/AR融合，实现沉浸式展示；
- 5) 推进模型轻量化与边缘端部署，提升实时应用能力。

Criticism and correction

请老师批评指正！